

Universidad Privada Domingo Savio
Facultad de Ingeniería / Carrera de Ingeniería de Sistemas

De la Brecha Analítica al Dato Accionable: Diagnóstico, Arquitectura y Pipeline de Business Intelligence para Oriental Mercantil S.R.L.

Asignatura: Inteligencia de Negocios y E-Business (DataBI – Proyecto Integrador)

Docente: Jimmy Nataniel Requena Llorentty

Estudiantes:

Yenny Serrudo Peña
Robert Denick Gomez Villagomez
Paulo Andrés Medina Montero

Santa Cruz de la Sierra, Bolivia – 2026

Tabla de Contenidos

Tabla de Contenidos	2
Resumen Ejecutivo	3
Introducción	4
Organización Analizada: Descripción y Diagnóstico Inicial.....	5
Arquitectura E-Business y Flujo BI.....	6
Diseño del Data Warehouse: Modelo Estrella y Pipeline Bronze-Silver-Gold	8
Implementación del Pipeline KDD en PySpark.....	9
Análisis RFM y Segmentación de Clientes	10
Dashboard Interactivo: Diseño y Hallazgos	11
Data Story y Recomendaciones Estratégicas.....	13
Reflexión Crítica del Proceso de Aprendizaje	13
Conclusiones.....	14

Resumen Ejecutivo

Este informe integra tres componentes del proyecto DataBI desarrollado para el caso Oriental Mercantil S.R.L., pyme boliviana dedicada a la comercialización de equipos de cómputo y periféricos en Santa Cruz de la Sierra, La Paz, Cochabamba y Sucre. El objetivo es presentar de forma unificada el diagnóstico organizacional, el diseño de la arquitectura E-Business, la construcción de un pipeline de datos bajo el modelo medallón (Bronze–Silver–Gold) en Databricks y PySpark, y la evaluación de un dashboard ejecutivo construido en Looker Studio.

El diagnóstico inicial, sustentado en el modelo de madurez analítica de Davenport y Harris (2007), ubicó a la organización en el Nivel 2 (Analítica Limitada), caracterizado por el uso de hojas de cálculo dispersas y ausencia de integración entre sistemas de ventas y contabilidad. A partir de este diagnóstico se propuso una arquitectura E-Business en cuatro capas y un flujo de inteligencia de negocios de seis etapas (fuentes, ingesta, almacenamiento, procesamiento, visualización y decisión), contrastando el escenario actual (AS-IS) con uno propuesto (TO-BE) basado en herramientas de bajo costo como PostgreSQL, Power BI y Looker Studio.

Sobre esa base conceptual se implementó un pipeline KDD real en Databricks Community Edition: la capa Bronze ingirió 2,847 registros crudos con metadatos de auditoría; la capa Silver aplicó cuatro reglas de limpieza (homologación de precios, renombrado, filtrado de valores no positivos y cálculo de TotalVenta) sin pérdida de registros; y la capa Gold materializó un modelo estrella con una tabla de hechos y cinco dimensiones, validado con cero claves huérfanas. El dashboard construido en Looker Studio, alimentado por 240 registros de venta de 2025, reportó ventas totales de Bs514,920 y evidenció una fuerte concentración de ingresos en dos de seis productos (78%), una caída sistemática de ventas los viernes y, como hallazgo crítico, una anomalía de calidad de

datos: las cuatro zonas comerciales presentan cifras idénticas, lo que sugiere una réplica del dato de origen antes que una captura independiente por ciudad.

El informe concluye que, si bien la arquitectura técnica y el pipeline de datos cumplen los estándares metodológicos esperados (KDD, modelo medallón, modelo estrella), la confiabilidad del dato de origen —y no el diseño analítico— constituye la principal limitación para que Oriental Mercantil utilice estas herramientas en decisiones de inversión por zona. Se recomienda auditar el pipeline de generación del dato, incorporar una dimensión de cliente para habilitar un análisis RFM completo, y avanzar de forma incremental hacia niveles superiores de madurez analítica.

Introducción

La transformación digital de las pequeñas y medianas empresas (pymes) en América Latina enfrenta una brecha estructural que combina limitaciones de infraestructura, capital humano y cultura organizacional orientada a la evidencia (CEPAL, 2024a). Según cifras citadas por la CEPAL (2025), la región concentra apenas el 1,56% del gasto mundial en inteligencia artificial, y Bolivia presenta rezagos adicionales: solo el 57,7% de su población interactúa activamente con plataformas digitales y la bancarización mediante tarjetas de crédito no supera el 12,6% (Estudios y Perspectivas, 2024).

Esta brecha analítica —entendida como la distancia entre el potencial de las herramientas de Business Intelligence (BI) y su nivel real de adopción (Davenport & Harris, 2007)— es particularmente visible en empresas de distribución y comercio minorista, sector en el que se ubica Oriental Mercantil S.R.L. La empresa, si bien genera datos transaccionales de forma cotidiana, no cuenta con un sistema integrado que permita explotarlos analíticamente para la toma de decisiones.

El presente informe se justifica por la necesidad de documentar, de manera integrada, el recorrido completo de un proyecto de inteligencia de negocios: desde el diagnóstico de madurez analítica y el diseño de una arquitectura E-Business, pasando por la construcción técnica de un pipeline de datos bajo el modelo medallón (Bronze, Silver, Gold) en Databricks, hasta la evaluación crítica de un dashboard ejecutivo en Looker Studio. Esta integración permite evidenciar no solo las capacidades técnicas desarrolladas, sino también las limitaciones reales que enfrenta una pyme boliviana al intentar dar el salto de una gestión intuitiva a una gestión basada en datos.

Organización Analizada: Descripción y Diagnóstico Inicial

Oriental Mercantil S.R.L. es una empresa boliviana con sede en Santa Cruz de la Sierra, dedicada a la comercialización de equipos de cómputo, periféricos, componentes de hardware y soluciones tecnológicas, con operaciones que se extienden a las ciudades de La Paz, Cochabamba y Sucre. Fundada en 2009, cuenta con aproximadamente 45 empleados y opera bajo un modelo de distribución que atiende tanto a clientes individuales como a empresas e instituciones educativas del eje troncal boliviano. Sus ingresos anuales se estiman entre Bs2.500.000 y Bs3.500.000, lo que la clasifica como pyme según el criterio de la Cámara de Comercio e Industria de Santa Cruz (CAINCO).

El entorno digital actual de la empresa se apoya en conexión de fibra óptica, presencia básica en redes sociales sin sitio web propio, y canales de venta dominados por llamadas telefónicas (60%) y WhatsApp Business (35%), sin integración entre estos canales y los registros de venta. Las operaciones se gestionan mediante hojas de cálculo Excel y un software contable básico (Monica 9), sin un sistema ERP integrado.

Aplicando el modelo de cinco niveles de madurez analítica de Davenport y Harris (2007), la organización fue posicionada en el Nivel 2 – Analítica Limitada, evidenciado por registros de ventas sin estructura normalizada, ausencia de integración entre ventas e inventario, y decisiones operativas dependientes del criterio del gerente-propietario.

Tabla 1

Nivel	Denominación	Características clave	Herramientas típicas
1	Sin analítica (ad-hoc)	Sin datos sistematizados; decisiones basadas en intuición	Libreta, Excel esporádico
2 ←	Analítica limitada	Reportes básicos en Excel; datos aislados por área; análisis reactivo	Excel, Monica/SAFI básico
3	Analítica descriptiva	Dashboards estáticos; 2-3 sistemas integrados; KPIs definidos	Power BI, Tableau, SQL Server
4	Analítica predictiva	Modelos estadísticos y de ML; pronósticos de demanda	Python/R, Azure ML, Qlik Sense
5	Analítica prescriptiva	IA para recomendaciones automáticas; optimización en tiempo real	GPT, AutoML, plataformas cloud BI

Nota. Elaboración propia a partir del modelo de Davenport y Harris (2007), adaptado con los indicadores de Rojas Layza et al. (2025). La flecha señala el nivel actual de Oriental Mercantil S.R.L. (Nivel 2).

Arquitectura E-Business y Flujo BI

El diagrama E-Business de Oriental Mercantil se estructuró en cuatro capas: (a) stakeholders externos —proveedores mayoristas, clientes minoristas y transportistas—; (b) canales digitales actuales —WhatsApp Business, redes sociales, llamadas telefónicas y correo electrónico—; (c) sistemas internos existentes —Excel para ventas e inventario, Monica 9 para contabilidad, y un portal de pedidos aún no implementado—; y (d) infraestructura tecnológica —red Wi-Fi, dispositivos móviles y un servidor de archivos compartidos. El análisis de este diagrama reveló tres brechas críticas de integración: la ausencia de un sistema de gestión de pedidos conectado al inventario, la desconexión entre ventas y contabilidad que genera doble registro manual, y la inexistencia de un canal digital autónomo para que los clientes generen pedidos.

Tabla 2

Capa	Componentes actuales	Brecha identificada
Stakeholders externos	Proveedores mayoristas, clientes minoristas, transportistas	Sin portal de autoservicio para clientes
Canales digitales	WhatsApp Business, Facebook/Instagram, llamadas telefónicas, correo esporádico	Canales no integrados entre sí
Sistemas internos	Excel (ventas/inventario), Monica 9 (contabilidad), portal de pedidos (no implementado)	Doble registro manual ventas–contabilidad
Infraestructura tecnológica	Red Wi-Fi, dispositivos móviles, servidor de archivos	Sin repositorio centralizado de datos

Nota. Elaboración propia a partir del diagrama E-Business_OrienteMercantil incluido en el informe de Actividad 1.

El flujo de inteligencia de negocios se definió en seis etapas secuenciales —fuentes, ingesta, almacenamiento, procesamiento, visualización y decisión (Eckerson, 2007)— comparando la situación actual (AS-IS) con una arquitectura propuesta (TO-BE). En el escenario actual, la ingesta es manual, el almacenamiento se realiza en carpetas compartidas, el procesamiento depende de fórmulas de Excel y la decisión final recae en la intuición del propietario. El escenario propuesto incorpora herramientas ETL de bajo costo (Apache NiFi, scripts Python), un Data Warehouse en PostgreSQL con esquema estrella, procesamiento con dbt/Pandas/Power Query, visualización en Power BI o Looker Studio, y un tablero de alertas automáticas como soporte a la decisión.

Tabla 3

Etapas	Situación actual (AS-IS)	Arquitectura propuesta (TO-BE)
Fuentes	Excel, Monica 9, WhatsApp, Facebook	ERP Odoo CE, Google Forms, POS digital
Ingesta	Copia manual de archivos	Apache NiFi, scripts Python ETL, conectores API
Almacenamiento	Carpetas compartidas, discos locales	PostgreSQL + Data Warehouse (esquema estrella)
Procesamiento	Fórmulas de Excel manuales	dbt, Python (Pandas), Power Query
Visualización	Reportes impresos, tablas Excel	Power BI Desktop, Google Looker Studio
Decisión	Intuición del propietario	Tablero de decisiones con alertas automáticas

Nota. Elaboración propia a partir del mapa de flujo BI (FlujoBi_OrientMercantil) del informe de Actividad 1, con base en Eckerson (2007) y Rojas Layza et al. (2025).

Para la primera fase de implementación se priorizaron cuatro KPI directamente calculables con los datos ya generados por la empresa: rotación de inventario por categoría, margen bruto por cliente y canal, tasa de pedidos cumplidos a tiempo, y tendencia de ventas semanal o mensual por zona geográfica.

Diseño del Data Warehouse: Modelo Estrella y Pipeline Bronze-Silver-Gold

La arquitectura de datos implementada sobre Databricks Community Edition siguió el modelo medallón de tres capas (Databricks, 2023), en el que cada capa cumple un propósito diferenciado: Bronze preserva la fidelidad al dato original, Silver aplica reglas de limpieza y estandarización, y Gold expone un modelo dimensional listo para el consumo analítico. La capa Gold materializó un modelo estrella clásico (Kimball & Ross, 2013), compuesto por una tabla de hechos central (Fact_Ventas) y cinco dimensiones: Producto, Tiempo, Zona, Cliente y Proveedor.

Tabla 4

Columna	Tipo	Rol	Descripción
SalesSK	Long	Clave primaria	ID único generado con monotonically_increasing_id()
ProductSK	Integer	Clave foránea	Referencia a DimProducto
DateSK	Integer	Clave foránea	Referencia a DimTiempo (formato YYYYMMDD)
ZonaSK	Integer	Clave foránea	Referencia a DimZona
CantidadVendida	Integer	Medida aditiva	Unidades vendidas por transacción
PrecioUnitario	Decimal(10,2)	Medida semiaditiva	Precio por unidad en bolivianos
TotalVenta	Decimal(12,2)	Medida aditiva	Ingreso total de la línea de venta

Nota. Elaboración propia a partir de la Celda 9 del notebook de Databricks, descrita en el informe del pipeline KDD.

La elección de un modelo estrella —en lugar de un esquema en copo de nieve o normalizado— responde a su mejor rendimiento en consultas de agregación y a su simplicidad para usuarios de negocio que consumen los datos mediante herramientas como Power BI o Looker Studio (Inmon, 2005). La validación de integridad referencial mediante left_anti joins confirmó cero registros huérfanos tanto en ProductSK como en ZonaSK, garantizando la consistencia del modelo antes de su explotación analítica.

Implementación del Pipeline KDD en PySpark

El pipeline de Descubrimiento de Conocimiento en Bases de Datos (KDD; Fayyad et al., 1996) se implementó sobre Apache Spark mediante un notebook de doce celdas organizado en las tres capas del modelo medallón. La capa Bronze ingirió 2,847 registros desde la tabla workspace.default.proyecto_ventas_computadoras_perifericos del Unity Catalog, añadiendo metadatos de auditoría (_ingest_time, _source_file) y persistiendo el resultado en formato Delta Lake.

La capa Silver aplicó cinco reglas de transformación secuenciales sobre el dataframe base, descritas en la Tabla 5. Todas las reglas conservaron la totalidad de los 2,847 registros, lo que se interpreta en el informe original como evidencia de ausencia de datos atípicos severos en el dataset fuente.

Tabla 5

Regla	Descripción	Función PySpark	Filas resultantes
0	Homologación de PrecioUnitario: comas por puntos y cast a double	regexp_replace + trim + cast('double')	2,847
1	Renombramiento: 'Cantidad' → 'CantidadVendida'	withColumnRenamed()	2,847

2	Filtrado: CantidadVendida > 0 y PrecioUnitario > 0.0	filter(col > 0)	2,847
3	Parsing de fecha a Timestamp; generación de DateSK	to_timestamp() + date_format() + cast('int')	2,847
4	Cálculo de TotalVenta = CantidadVendida × PrecioUnitario	round(col * col, 2)	2,847

Nota. Elaboración propia a partir de las Celdas 4 y 5 del notebook de Databricks, descritas en el informe del pipeline KDD.

Una auditoría de calidad analítica (Celda 6) verificó cero valores nulos en los campos críticos DateSK, TotalVenta, CantidadVendida, PrecioUnitario, Producto y Area, así como cero registros con cantidad menor o igual a cero. En la capa Gold, las dimensiones Tiempo, Zona y Producto se construyeron mediante claves sustitutas generadas con row_number() sobre ventanas ordenadas, y la tabla de hechos se ensambló mediante joins de tipo LEFT JOIN entre la capa Silver y las dimensiones.

Sobre este modelo se generaron cuatro visualizaciones analíticas en el propio notebook: evolución mensual de ingresos, rendimiento comparativo por zonas geográficas, top de productos por ingresos, y una matriz de dispersión entre precio unitario y cantidad vendida sobre una muestra aleatoria estratificada del 10% de los registros. Cabe señalar una diferencia de volumen entre este pipeline (2,847 registros crudos en Databricks) y el dataset final de 240 registros utilizado en el dashboard de Looker Studio, lo que sugiere que este último se alimentó de un extracto o agregado posterior del pipeline completo.

Análisis RFM y Segmentación de Clientes

El diseño original del proyecto contempló un análisis de tipo RFM (Recencia, Frecuencia, Monetary) para segmentar clientes según su comportamiento de compra. Sin embargo, el dataset transaccional disponible —tanto en la capa Gold de Databricks como en el extracto utilizado en Looker Studio— no incluye una dimensión de cliente individualizada: los registros identifican

producto, zona, fecha y monto de venta, pero no un identificador de comprador recurrente. Por esta razón, el equipo adaptó el análisis a un cruce equivalente de frecuencia y valor monetario a nivel de producto, sustituyendo la dimensión ausente de cliente por la dimensión disponible de producto.

Este cruce, visualizado mediante un gráfico de dispersión de cantidad vendida (proxy de frecuencia) contra el monto total de venta (monetary) por producto, mostró que el volumen de unidades no es proporcional al ingreso generado: productos como Mouse y Teclado mueven cantidades comparables a las de Laptop y PC Escritorio (entre 216 y 272 unidades), pero generan entre 30 y 60 veces menos ingreso, como consecuencia directa de su bajo precio unitario (Bs15 y Bs25 frente a Bs850 y Bs700 de los equipos de cómputo). Esto confirma que el portafolio de periféricos aporta volumen, pero no valor agregado por unidad.

La imposibilidad de ejecutar un RFM propiamente dicho constituye, en sí misma, un hallazgo relevante del diagnóstico: confirma en la práctica la ausencia de un sistema de gestión de relación con el cliente (CRM) señalada en el diagnóstico de madurez analítica, y refuerza la recomendación —explícita en el informe del pipeline KDD— de incorporar una DimCliente en el modelo estrella como paso de mediano plazo, condición necesaria para segmentar clientes por recencia, frecuencia y valor monetario en fases futuras del proyecto.

Dashboard Interactivo: Diseño y Hallazgos

El dashboard de ventas se construyó en Looker Studio a partir de un archivo CSV exportado de la tabla Gold de Databricks, con 240 registros transaccionales del periodo enero-diciembre de 2025. Sobre esta fuente se definieron cuatro medidas base —Total Ventas, Cantidad Vendida, Record Count y Ticket Promedio por Venta— que alimentan seis componentes visuales: tres tarjetas KPI,

un gráfico de barras apiladas de ventas por día de la semana segmentado por categoría, un gráfico de barras agrupadas de ventas por producto segmentado por zona, un gráfico de área de tendencia semanal, una tabla de zonas con ticket promedio, y un gráfico de dispersión de cantidad versus monto por producto.

Tabla 6

Dimensión analizada	Hallazgo	Implicancia de negocio
Desempeño general	Bs514,920 en ventas; 1,496 unidades; 240 transacciones; ticket promedio Bs2,145.5	El ticket promedio, no el volumen, es el principal motor de ingresos
Concentración de producto	Laptop y PC Escritorio concentran el 78% de los ingresos	Riesgo de dependencia sobre solo dos de seis productos
Estacionalidad semanal	El viernes vende 59% menos que el lunes	Patrón estructural que amerita acción comercial específica
Calidad del dato por zona	Las cuatro zonas reportan cifras idénticas (Bs128,730 c/u)	Anomalía crítica: sugiere réplica del dato, no captura independiente

Nota. Elaboración propia a partir de la Figura 1 y los resultados descritos en el informe de evaluación del dashboard (Actividad 4).

En términos de calidad visual y funcional, el tablero exhibe fortalezas —tarjetas KPI de lectura inmediata, jerarquía visual en Z, y un gráfico de dispersión poco frecuente en dashboards de pyme que resulta apropiado para detectar productos de alto volumen y bajo valor— junto a áreas de mejora: ausencia de filtros interactivos visibles (fecha, zona, categoría) más allá de un botón de restablecer, inconsistencia de idioma en los rótulos (mezcla de español e inglés), y una tabla de zonas ordenada como ranking del 1 al 4 pese a que las cuatro zonas presentan valores idénticos.

El hallazgo más relevante de la evaluación no es de diseño, sino de calidad del dato subyacente: al desagregar el Total de Ventas por zona, las cuatro ciudades muestran exactamente el mismo monto y el mismo ticket promedio, y un análisis a nivel de registro confirma que cada combinación de producto y fecha se repite de forma idéntica en las cuatro zonas. Esta uniformidad perfecta es

estadísticamente improbable en datos capturados de forma independiente por ciudad y sugiere que, en algún punto del pipeline —ya sea en la generación de la tabla Gold o en un paso previo de simulación de datos—, el registro de una sola zona fue replicado para las cuatro.

Data Story y Recomendaciones Estratégicas

Siguiendo la estructura de storytelling con datos de Knafllic (2015), los hallazgos del dashboard se organizaron en una historia de datos de tres actos. El Acto I (la situación) presenta a Oriental Mercantil, el origen del dato (Databricks → Looker Studio) y una fotografía general del negocio en 2025. El Acto II (el conflicto) expone cuatro señales de alerta: la concentración de ingresos en dos productos, la caída de ventas los viernes, un portafolio de periféricos de alto volumen y bajo valor agregado, y la anomalía de calidad de datos por zona. El Acto III (la resolución) cierra con recomendaciones accionables y una hoja de ruta de corto, mediano y largo plazo.

Tabla 7

Horizonte	Recomendaciones
Corto plazo	Auditar con el equipo de Databricks el proceso de generación de la tabla Gold para confirmar o descartar la réplica de datos entre zonas antes de tomar decisiones de inversión regional; incorporar filtros visibles de fecha, zona y categoría en Looker Studio; unificar el idioma de los rótulos del dashboard.
Mediano plazo	Diversificar el portafolio de producto impulsando accesorios y servicios de mayor margen; diseñar una acción comercial específica para los viernes; incorporar una DimCliente que habilite un análisis RFM completo; implementar un proceso de carga incremental (CDC) que reemplace las cargas completas actuales.
Largo plazo	Migrar hacia procesamiento en tiempo real (Structured Streaming); desarrollar modelos predictivos de demanda sobre las tablas Gold; certificar el proceso bajo un marco de gobernanza de datos (p. ej., DAMA-DMBOK).

Nota. Elaboración propia a partir de las recomendaciones de los informes de Actividad 4 y del pipeline KDD.

Reflexión Crítica del Proceso de Aprendizaje

El desarrollo integrado de este proyecto —desde el diagnóstico de madurez analítica hasta la evaluación de un dashboard ejecutivo— permitió al equipo experimentar de primera mano una tensión que la literatura académica suele abordar de forma separada: la distancia entre el rigor técnico de un pipeline de datos bien diseñado y la confiabilidad del dato que ese pipeline procesa. El modelo medallón, el modelo estrella y las reglas de calidad aplicadas en Silver cumplieron los estándares metodológicos esperados —cero nulos, cero huérfanos, cero registros descartados—, y sin embargo el hallazgo más importante del proyecto (la réplica de datos entre zonas) no fue detectado por ninguna de esas validaciones automáticas, sino por una inspección manual y crítica del resultado final en el dashboard.

Esta experiencia reforzó una lección central de la inteligencia de negocios aplicada a contextos de pyme: la validación técnica de un pipeline (integridad referencial, ausencia de nulos, tipado correcto) es una condición necesaria pero no suficiente para garantizar la calidad analítica del dato. Asimismo, la imposibilidad de ejecutar un análisis RFM completo por ausencia de una dimensión de cliente evidenció, de forma práctica, cómo las limitaciones estructurales de un caso real de pyme boliviana condicionan qué preguntas de negocio pueden responderse, independientemente de la sofisticación técnica del pipeline construido. El ejercicio de adaptar la consigna original a los datos realmente disponibles se valora como un aprendizaje tan importante como la implementación técnica misma.

Conclusiones

El proyecto desarrollado para Oriental Mercantil S.R.L. demuestra que es posible construir, con herramientas gratuitas o de bajo costo, un recorrido completo de inteligencia de negocios que va desde el diagnóstico de madurez analítica hasta un dashboard ejecutivo, pasando por un pipeline

de datos técnicamente robusto bajo el modelo medallón y un modelo estrella con integridad referencial validada. La organización, diagnosticada en el Nivel 2 de madurez analítica, cuenta con condiciones habilitantes suficientes —conectividad, disposición de la gerencia y generación cotidiana de datos transaccionales— para avanzar de forma incremental hacia el Nivel 3.

No obstante, la evaluación crítica del dashboard reveló que la principal barrera no es de diseño visual ni de arquitectura técnica, sino de confiabilidad del dato de origen: la anomalía de réplica entre zonas comerciales compromete cualquier decisión de inversión geográfica que se apoye en el estado actual del tablero. En consecuencia, la recomendación prioritaria del equipo es que Oriental Mercantil audite el origen del dato antes de continuar invirtiendo en mejoras de visualización o en la incorporación de nuevas dimensiones analíticas como el cliente, condición que también resulta necesaria para completar en el futuro un análisis RFM que hoy no es posible ejecutar.