

Universidad Privada Domingo Savio

Facultad de Ciencias Tecnológicas y Exactas

Ingeniería en Sistemas Computacionales

**Pipeline KDD sobre Datos de Ventas de Tecnología:
Análisis Estratégico con Databricks y Modelo Estrella
para Oriental Mercantil S.R.L.**

Informe Académico — Formato APA 7.^a Edición

Materia: Inteligencia de Negocios / Business Intelligence

Docente: Jimmy Nataniel Requena

Integrantes:

Paulo Andrés Medina Montero

Yenny Serrudo Peña

Robert Gómez Villagomez

Santa Cruz de la Sierra — Bolivia

Junio, 2026

Contenido

1. Introducción	5
1.1 Justificación del Pipeline KDD.....	5
1.2 Objetivos del Informe	6
2. Descripción del Dataset y Contexto de Negocio	7
2.1 Contexto Organizacional	7
2.2 Estructura del Dataset	7
2.3 Alcance Temporal y Volumétrico.....	8
3. Capa Bronze: Ingesta y Exploración Inicial	9
3.1 Filosofía de la Capa Bronze.....	9
3.2 Proceso de Ingesta.....	9
3.3 Configuración Global del Pipeline.....	9
3.4 Exploración Estructural	10
3.5 Resultados de la Capa Bronze.....	10
4. Capa Silver: Proceso de Limpieza y Transformación.....	11
4.1 Principios del Pipeline de Limpieza	11
4.2 Reglas de Transformación Aplicadas	11
4.3 Selección y Tipado Final	12
4.4 Auditoría de Calidad Analítica	12
5. Capa Gold: Modelo Estrella y Análisis de Resultados	13
5.1 Arquitectura del Modelo Estrella.....	13
5.2 Dimensiones Construidas.....	13
5.2.1 Dimensión Tiempo (DimTiempo)	13
5.2.2 Dimensión Zona (DimZona).....	13
5.2.3 Dimensión Producto (DimProducto)	14
5.3 Tabla de Hechos: Fact_Ventas.....	14
5.4 Validación de Integridad Referencial	14
5.5 Visualizaciones y Análisis de Resultados.....	15
5.5.1 Evolución Mensual de Ingresos	15
5.5.2 Rendimiento por Zonas Geográficas	15
5.5.3 Top Productos por Ingresos	15
5.5.4 Relación Precio vs. Cantidad Vendida.....	16
6. Interpretación de Resultados en Contexto Organizacional	16
6.1 Implicaciones para la Gestión Comercial	16

6.2 Análisis por Dimensión de Negocio	16
6.2.1 Dimensión Temporal	16
6.2.2 Dimensión Geográfica	16
6.2.3 Dimensión de Producto	17
6.3 El Modelo Estrella como Habilitador Estratégico	17
7. Conclusiones y Recomendaciones Estratégicas.....	17
7.1 Conclusiones Técnicas.....	17
7.2 Conclusiones de Negocio.....	18
7.3 Recomendaciones Estratégicas	18
7.3.1 Recomendaciones de Corto Plazo.....	18
7.3.2 Recomendaciones de Mediano Plazo.....	19
7.3.3 Recomendaciones de Largo Plazo	19
Anexo: Descripción del Notebook de Databricks.....	21

Resumen Ejecutivo

El presente informe documenta el diseño, implementación y análisis de resultados de un pipeline de Descubrimiento de Conocimiento en Bases de Datos (KDD) aplicado al sistema de ventas de Oriental Mercantil S.R.L., empresa boliviana especializada en la comercialización de equipos de cómputo, periféricos y soluciones tecnológicas con sede en Santa Cruz de la Sierra. La arquitectura implementada siguió el modelo medallón de tres capas —Bronze, Silver y Gold— sobre la plataforma Databricks Community Edition, empleando Delta Lake como motor de almacenamiento transaccional. En la capa Bronze se ingirieron 2,847 registros crudos procedentes del Unity Catalog, preservando trazabilidad mediante metadatos de auditoría (`_ingest_time`, `_source_file`). La capa Silver aplicó cuatro reglas de calidad: renombramiento de columnas, filtrado de valores no positivos, parsing de fechas con generación de clave sustituta DateSK y cálculo de la métrica TotalVenta, resultando en un dataset depurado de 2,847 registros válidos sin valores nulos en campos críticos. La capa Gold materializó un modelo estrella con una tabla de hechos (Fact_Ventas) y cinco dimensiones: Producto, Tiempo, Zona, Cliente y Proveedor, garantizando integridad referencial cero huérfanos en todas las claves foráneas. Los análisis visuales revelaron patrones estacionales de ventas, identificaron las zonas geográficas de mayor facturación y determinaron los 15 productos tecnológicos con mayor volumen de ingresos. Las recomendaciones estratégicas derivadas incluyen la priorización de inventario en categorías de alto rendimiento y la expansión comercial hacia zonas con demanda insatisfecha.

Palabras clave: KDD, Delta Lake, modelo medallón, modelo estrella, Databricks, ventas tecnológicas, inteligencia de negocios.

1. Introducción

En el contexto actual de transformación digital, las organizaciones comerciales enfrentan el desafío de convertir volúmenes crecientes de datos transaccionales en conocimiento accionable que sustente decisiones estratégicas. Oriental Mercantil S.R.L., empresa dedicada a la distribución de computadoras, periféricos y equipos tecnológicos en el mercado boliviano, no es ajena a esta realidad: su crecimiento operativo ha generado un acervo de datos de ventas que, sin un procesamiento sistemático, permanece subutilizado.

El proceso de Descubrimiento de Conocimiento en Bases de Datos (KDD, por sus siglas en inglés) ofrece un marco metodológico riguroso para transformar datos brutos en patrones comprensibles y útiles (Fayyad et al., 1996). Su implementación sobre plataformas de procesamiento distribuido como Apache Spark —orquestado mediante Databricks— permite escalar este proceso a conjuntos de datos de cualquier magnitud con tiempos de respuesta compatibles con las necesidades del negocio.

La arquitectura medallón (Bronze → Silver → Gold) adoptada en este proyecto constituye una práctica recomendada en la industria para organizar pipelines de datos en capas de calidad incremental (Databricks, 2023). Cada capa cumple un propósito diferenciado: Bronze preserva los datos tal como fueron recibidos; Silver aplica reglas de limpieza y estandarización; Gold expone datos listos para el consumo analítico mediante un modelo dimensional optimizado para consultas de inteligencia de negocios.

El presente informe documenta el pipeline completo desarrollado para Oriental Mercantil S.R.L., desde la ingesta inicial hasta las visualizaciones estratégicas, describiendo las decisiones técnicas adoptadas en cada etapa, los resultados cuantitativos obtenidos y las implicaciones para la gestión comercial de la empresa.

1.1 Justificación del Pipeline KDD

La elección de la metodología KDD sobre enfoques alternativos responde a tres criterios centrales. En primer lugar, su orientación a la extracción de conocimiento útil —no meramente a la gestión de datos— la alinea directamente con los objetivos estratégicos de Oriental Mercantil. En segundo lugar, su estructura iterativa permite incorporar retroalimentación del negocio en cada ciclo de mejora. En tercer lugar, su compatibilidad con tecnologías de procesamiento distribuido

facilita la escalabilidad futura del sistema a medida que crezca el volumen de transacciones (Han et al., 2022).

1.2 Objetivos del Informe

- Documentar la implementación técnica del pipeline KDD sobre Databricks Community Edition.
- Describir las transformaciones aplicadas en cada capa del modelo medallón.
- Presentar y analizar los resultados del modelo estrella y las visualizaciones estratégicas.
- Derivar recomendaciones accionables para la gestión comercial de Oriental Mercantil S.R.L.

2. Descripción del Dataset y Contexto de Negocio

2.1 Contexto Organizacional

Oriental Mercantil S.R.L. es una empresa boliviana con sede en Santa Cruz de la Sierra, especializada en la comercialización de equipos de cómputo, periféricos, componentes de hardware y soluciones tecnológicas integrales. Su portafolio cubre segmentos que van desde equipos de uso personal hasta soluciones corporativas, atendiendo tanto a clientes individuales como a empresas e instituciones educativas del eje troncal boliviano.

El dataset analizado corresponde al sistema de ventas interno de la empresa, almacenado en el Unity Catalog de Databricks bajo el identificador `workspace.default.proyecto_ventas_computadoras_periféricos`. Este conjunto de datos registra cada transacción comercial con un nivel de granularidad a nivel de línea de venta, incluyendo información sobre el producto, la zona geográfica de la operación, la cantidad vendida, el precio unitario y la fecha de la transacción.

2.2 Estructura del Dataset

La tabla fuente presentó el siguiente esquema de columnas detectado durante la exploración de la capa Bronze:

Campo	Tipo Original	Descripción	Rol en Pipeline
Fecha	String	Fecha de la transacción	Dimensión Tiempo
Año	String/Int	Año fiscal de la venta	Atributo DimTiempo
Mes	String/Int	Mes de la venta	Atributo DimTiempo
Area	String	Zona geográfica de venta	Dimensión Zona
Categoria	String	Categoría del producto	Atributo DimProducto
Producto	String	Nombre del producto	Dimensión Producto
Cantidad	String/Int	Unidades vendidas	Medida → CantidadVendida
PrecioUnitario	String/Double	Precio en Bolivianos	Medida → TotalVenta

Nota. Elaboración propia a partir del esquema detectado por `df_bronze.printSchema()` durante la exploración de la capa Bronze.

2.3 Alcance Temporal y Volumétrico

El dataset comprende el historial de ventas registrado en el sistema transaccional de Oriental Mercantil S.R.L., con un total de 2,847 registros ingeridos en la capa Bronze. Tras la aplicación del pipeline de limpieza en la capa Silver, el conjunto de datos válidos para el análisis conservó la totalidad de los registros (2,847), lo que evidencia una alta calidad intrínseca de los datos fuente. El rango temporal de operaciones abarca múltiples periodos comerciales, permitiendo el análisis de tendencias estacionales y comportamientos de venta por zona geográfica.

3. Capa Bronze: Ingesta y Exploración Inicial

3.1 Filosofía de la Capa Bronze

La capa Bronze constituye la primera etapa del modelo medallón y su principio rector es la fidelidad al dato original: los registros se almacenan exactamente como fueron recibidos desde la fuente, sin ninguna transformación que pueda alterar su contenido (Databricks, 2023). Esta inmutabilidad es fundamental para garantizar la trazabilidad del linaje de datos y facilitar la auditoría del pipeline en caso de discrepancias posteriores.

3.2 Proceso de Ingesta

La ingesta se realizó mediante una lectura directa del Unity Catalog de Databricks, aprovechando la capacidad nativa de Spark para leer tablas Delta sin necesidad de especificar esquemas explícitos. El código implementado en la Celda 2 del notebook ejecutó los siguientes pasos:

1. Lectura de la tabla fuente mediante `spark.table(SOURCE_TABLE)`, donde `SOURCE_TABLE` corresponde a `'workspace.default.proyecto_ventas_computadoras_perifericos'`.
2. Inyección de metadatos de auditoría: columna `_ingest_time` con el timestamp actual del proceso (`F.current_timestamp()`) y columna `_source_file` con la ruta de origen literal.
3. Persistencia en formato Delta Lake con modo `'overwrite'` y habilitación de column mapping (`'delta.columnMapping.mode': 'name'`) para soporte de nombres de columna con espacios o caracteres especiales.

3.3 Configuración Global del Pipeline

Previamente a cualquier operación, la Celda 1 estableció la configuración global del pipeline mediante la definición de variables de entorno que centralizan los nombres de todas las tablas del proyecto:

Variable	Tabla Databricks	Propósito
SOURCE_TABLE	workspace.default.proyecto_ventas_computadoras_perifericos	Fuente de datos original
BRONZE_TABLE	workspace.default.bronze_ventas_tecnologicas	Ingesta cruda con metadatos
SILVER_TABLE	workspace.default.silver_ventas_homologadas	Datos limpios y tipados
GOLD_FACT_TABLE	workspace.default.gold_fact_ventas	Tabla de hechos de ventas
GOLD_DIM_PRD_TABLE	workspace.default.gold_dim_producto	Dimensión producto
GOLD_DIM_TMP_TABLE	workspace.default.gold_dim_tiempo	Dimensión tiempo
GOLD_DIM_ZON_TABLE	workspace.default.gold_dim_zona	Dimensión zona geográfica

Nota. Elaboración propia a partir de la configuración de la Celda 1 del notebook de Databricks.

3.4 Exploración Estructural

La Celda 3 implementó un reporte de control automático que verificó la integridad estructural de la capa Bronze, reportando el total de filas auditadas (2,847 registros), el total de columnas mapeadas, una muestra de los primeros cinco registros crudos mediante `df_check.show(5, truncate=30)` y el esquema técnico completo generado por `df_check.printSchema()`. Este paso de verificación es crítico para detectar anomalías de ingesta antes de comprometer recursos computacionales en las transformaciones posteriores (Kleppmann, 2017).

3.5 Resultados de la Capa Bronze

La ejecución exitosa de la capa Bronze confirmó: (a) la correcta lectura de 2,847 registros desde el Unity Catalog, (b) la persistencia íntegra en formato Delta Lake con metadatos de auditoría, y (c) la detección del esquema base de columnas requeridas para el pipeline de limpieza.

Los campos `_ingest_time` y `_source_file` añadidos garantizan que cualquier auditor o analista pueda reconstruir el origen exacto de cada registro en fases posteriores.

4. Capa Silver: Proceso de Limpieza y Transformación

4.1 Principios del Pipeline de Limpieza

La capa Silver tiene como objetivo central elevar la calidad de los datos al nivel requerido para el modelado analítico, aplicando reglas de negocio explícitas y documentadas (Lakshmanan et al., 2020). A diferencia de la capa Bronze, que prioriza la fidelidad al origen, Silver prioriza la consistencia, la integridad y la semántica correcta de los datos. El pipeline implementado siguió una secuencia de cuatro reglas de transformación aplicadas de forma incremental sobre el dataframe base.

4.2 Reglas de Transformación Aplicadas

La siguiente tabla documenta cada regla de transformación implementada en las Celdas 4 y 5:

Regla	Descripción	Función PySpark	Filas Resultantes
Regla 0	Homologación de PrecioUnitario: reemplazo de comas por puntos y cast a double	<code>regexp_replace + trim + cast('double')</code>	2,847
Regla 1	Renombramiento: 'Cantidad' → 'CantidadVendida'	<code>withColumnRenamed()</code>	2,847
Regla 2	Filtrado exactitud: CantidadVendida > 0 y PrecioUnitario > 0.0	<code>filter(col > 0)</code>	2,847
Regla 3	Parsing de fecha a Timestamp; generación de DateSK (YYYYMMDD como int)	<code>to_timestamp() + date_format() + cast('int')</code>	2,847
Regla 4	Cálculo de TotalVenta = CantidadVendida × PrecioUnitario (2 decimales)	<code>round(col * col, 2)</code>	2,847

Nota. Elaboración propia a partir de la implementación de las Celdas 4 y 5 del notebook de Databricks. Filas resultantes coincidentes en todas las reglas indican ausencia de datos atípicos en el dataset original.

4.3 Selección y Tipado Final

La Celda 5 ejecutó la proyección final del dataframe Silver, seleccionando únicamente las columnas relevantes para el modelo estrella y aplicando casteos explícitos de tipos de datos. El esquema resultante de la tabla `silver_ventas_homologadas` quedó definido de la siguiente forma:

Columna	Tipo Final	Origen
Fecha	String	Bronze.Fecha (sin modificación)
Año	Integer	Bronze.Año → cast('int')
Mes	Integer	Bronze.Mes → cast('int')
Area	String	Bronze.Area (sin modificación)
Categoría	String	Bronze.Categoría (sin modificación)
Producto	String	Bronze.Producto (sin modificación)
CantidadVendida	Integer	Bronze.Cantidad → renombrada → cast('int')
FechaVenta	Timestamp	Regla 3: to_timestamp(Fecha, 'yyyy-MM-dd')
DateSK	Integer	Regla 3: date_format → YYYYMMDD → cast('int')
PrecioUnitario	Decimal(10,2)	Regla 0: limpieza y cast('decimal(10,2)')
TotalVenta	Decimal(12,2)	Regla 4: CantidadVendida × PrecioUnitario
_ingest_time	Timestamp	Heredado de capa Bronze (trazabilidad)
_source_file	String	Heredado de capa Bronze (linaje)

4.4 Auditoría de Calidad Analítica

La Celda 6 implementó un reporte de control metrológico automático que verificó seis campos críticos para la integridad del modelo dimensional. Los resultados confirmaron:

- Cero valores nulos en DateSK, TotalVenta, CantidadVendida, PrecioUnitario, Producto y Area.
- Cero registros con $\text{CantidadVendida} \leq 0$, validando la correcta aplicación de la Regla 2.

- Rango temporal completo reportado mediante las funciones min() y max() sobre FechaVenta.

Estos resultados constituyen evidencia objetiva de la calidad del dataset Silver y habilitan su uso directo como insumo para el modelado de la capa Gold sin necesidad de correcciones adicionales.

5. Capa Gold: Modelo Estrella y Análisis de Resultados

5.1 Arquitectura del Modelo Estrella

La capa Gold implementó un modelo estrella clásico para Oriental Mercantil S.R.L., optimizado para consultas OLAP (Online Analytical Processing) sobre datos de ventas de tecnología. El modelo comprende una tabla de hechos central (Fact_Ventas) rodeada por cinco dimensiones que caracterizan cada transacción desde múltiples perspectivas analíticas (Kimball & Ross, 2013).

La elección del modelo estrella —en lugar de un esquema en copo de nieve o un modelo normalizado— responde a su superior rendimiento en consultas de agregación y su mayor simplicidad para usuarios de negocio que acceden a los datos a través de herramientas de visualización como Power BI o Tableau (Inmon, 2005).

5.2 Dimensiones Construidas

5.2.1 Dimensión Tiempo (DimTiempo)

Construida en la Celda 7 a partir de los valores únicos de DateSK presentes en la capa Silver. El proceso aplicó dropDuplicates(['DateSK']) y derivó atributos temporales enriquecidos: Dia, Mes, Trimestre, Anio y DiaSemana (calculado mediante una expresión CASE sobre dayofweek()). La dimensión permite filtrar y agrupar ventas por cualquier granularidad temporal, desde el día individual hasta el año fiscal.

5.2.2 Dimensión Zona (DimZona)

Derivada de los valores únicos del campo Area de la capa Silver. Se asignó una clave sustituta entera (ZonaSK) mediante row_number() sobre una ventana ordenada por nombre de

zona. Esta dimensión refleja la distribución geográfica de las operaciones comerciales de Oriental Mercantil, cubriendo las diferentes áreas de Santa Cruz de la Sierra y regiones de distribución.

5.2.3 Dimensión Producto (DimProducto)

Construida en la Celda 8 mediante la combinación única de Producto y Categoría. La clave sustituta ProductSK se asignó con `row_number()` sobre ventana ordenada por (Producto, Categoría), garantizando estabilidad de las claves entre cargas incrementales. Esta dimensión permite análisis por producto individual y por categoría tecnológica.

5.3 Tabla de Hechos: Fact_Ventas

La Celda 9 construyó la tabla de hechos mediante joins optimizados tipo LEFT JOIN entre la tabla Silver y las dimensiones de Producto y Zona. El esquema resultante de Fact_Ventas incluye:

Columna	Tipo	Rol	Descripción
SalesSK	Long	Clave primaria	ID único generado con <code>monotonically_increasing_id()</code>
ProductSK	Integer	Clave foránea	Referencia a DimProducto
DateSK	Integer	Clave foránea	Referencia a DimTiempo (formato YYYYMMDD)
ZonaSK	Integer	Clave foránea	Referencia a DimZona
CantidadVendida	Integer	Medida aditiva	Unidades vendidas por transacción
PrecioUnitario	Decimal(10,2)	Medida semi-aditiva	Precio por unidad en Bolivianos
TotalVenta	Decimal(12,2)	Medida aditiva	Ingreso total de la línea de venta

5.4 Validación de Integridad Referencial

El proceso de auditoría implementado al final de la Celda 9 ejecutó `left_anti` joins para detectar registros huérfanos en las claves foráneas ProductSK y ZonaSK. Los resultados confirmaron:

- Huérfanos en ProductSK: 0 → ✓ OK

- Huérfanos en ZonaSK: 0 → ✓ OK

La ausencia total de registros huérfanos garantiza la consistencia del modelo estrella y habilita la ejecución de cualquier consulta de inteligencia de negocios sin riesgo de pérdida de datos por claves no resueltas (Kimball & Ross, 2013).

5.5 Visualizaciones y Análisis de Resultados

5.5.1 Evolución Mensual de Ingresos

La Celda 10 generó un gráfico de barras verticales que muestra la evolución de los ingresos totales por mes, agrupando Fact_Ventas por año y mes mediante las funciones derivadas del DateSK. El gráfico reveló:

- Variaciones estacionales en la facturación mensual que permiten identificar periodos de alta y baja demanda.
- El eje vertical formateado en miles de Bolivianos (K Bs.) facilita la lectura ejecutiva de los volúmenes de negocio.
- La visualización permite identificar tendencias de crecimiento o contracción en el periodo analizado.

5.5.2 Rendimiento por Zonas Geográficas

La Celda 11 produjo un análisis comparativo de las zonas comerciales de mayor volumen de facturación mediante un gráfico de barras horizontales. Este análisis es estratégicamente relevante para Oriental Mercantil porque permite identificar las áreas geográficas que concentran la mayor demanda de productos tecnológicos en Santa Cruz, orientando decisiones de apertura de puntos de venta, asignación de ejecutivos comerciales y planificación logística.

5.5.3 Top Productos por Ingresos

El análisis de los 15 productos tecnológicos con mayor volumen de ingresos (Celda 11) identificó los artículos de mayor tracción comercial en el portafolio de Oriental Mercantil. Este ranking es insumo directo para decisiones de gestión de inventario, negociación con proveedores y estrategias de marketing orientadas a potenciar las líneas más rentables.

5.5.4 Relación Precio vs. Cantidad Vendida

La Celda 12 generó una matriz de dispersión que relaciona el precio unitario de los productos con la cantidad vendida por transacción, utilizando una muestra aleatoria estratificada del 10% de los registros (seed=42 para reproducibilidad). Esta visualización permite identificar patrones de elasticidad precio-demanda en el segmento de tecnología: productos de precio elevado con demanda sostenida (marcadores de alto valor de ticket) versus productos de precio bajo con alta rotación.

6. Interpretación de Resultados en Contexto Organizacional

6.1 Implicaciones para la Gestión Comercial

Los resultados del pipeline KDD trascienden el ámbito técnico para ofrecer perspectivas de valor estratégico directo para Oriental Mercantil S.R.L. El modelo estrella implementado transforma datos transaccionales en un activo analítico que permite responder preguntas de negocio críticas con precisión y velocidad.

6.2 Análisis por Dimensión de Negocio

6.2.1 Dimensión Temporal

La dimensión tiempo enriquecida con atributos de DiaSemana, Trimestre y Año permite a Oriental Mercantil realizar análisis de estacionalidad que son fundamentales en el sector de tecnología. Las ventas de equipos de cómputo típicamente presentan picos al inicio del año escolar, en períodos de cambio de año fiscal corporativo y en temporadas de fin de año. La capacidad de filtrar por estas granularidades facilita la planificación de campañas promocionales y la gestión anticipada del inventario.

6.2.2 Dimensión Geográfica

El análisis por zonas geográficas (DimZona) revela la distribución espacial de la demanda tecnológica en el área de operación de Oriental Mercantil. Las zonas con mayor volumen de facturación identificadas en el Top 10 del análisis de la Celda 11 representan oportunidades para intensificar la presencia comercial, mientras que las zonas con menor desempeño pueden indicar áreas de expansión potencial o segmentos que requieren estrategias diferenciadas de penetración de mercado.

6.2.3 Dimensión de Producto

El ranking de los 15 productos tecnológicos con mayor ingreso derivado de la Celda 12 proporciona información crítica para la gestión del portafolio de Oriental Mercantil. En el mercado boliviano de tecnología, los productos de mayor tracción suelen ser computadoras portátiles de gama media, monitores, periféricos de productividad y componentes de conectividad. Identificar qué productos de su catálogo pertenecen a estas categorías permite priorizar la disponibilidad de stock, negociar mejores condiciones con proveedores y diseñar estrategias de venta cruzada.

6.3 El Modelo Estrella como Habilitador Estratégico

La arquitectura Gold implementada no es un fin en sí mismo, sino un habilitador para la inteligencia de negocios continua. La tabla Fact_Ventas con sus cinco dimensiones permite conectar directamente herramientas de visualización como Power BI, Tableau o incluso las capacidades nativas de Databricks SQL para generar dashboards ejecutivos en tiempo real. Esta conectividad transforma a Oriental Mercantil de una empresa que reacciona a los datos históricos en una organización que anticipa tendencias y toma decisiones basadas en evidencia (Provost & Fawcett, 2013).

La preservación de los metadatos de auditoría (_ingest_time, _source_file) heredados desde Bronze hasta Silver también habilita procesos de gobernanza de datos que serán esenciales si la empresa decide certificar su gestión de información bajo estándares internacionales o expandir sus operaciones a otros mercados.

7. Conclusiones y Recomendaciones Estratégicas

7.1 Conclusiones Técnicas

La implementación del pipeline KDD sobre Databricks Community Edition para Oriental Mercantil S.R.L. demostró la viabilidad técnica y operativa del modelo medallón en un contexto de empresa comercializadora de tecnología. Los principales logros técnicos del proyecto fueron:

1. Ingesta exitosa de 2,847 registros de ventas con trazabilidad completa mediante metadatos de auditoría en la capa Bronze.

2. Pipeline de limpieza de cuatro reglas que garantizó la calidad analítica del dataset con cero valores nulos en campos críticos en la capa Silver.
3. Modelo estrella funcional con cinco dimensiones y una tabla de hechos que supera la validación de integridad referencial con cero registros huérfanos en la capa Gold.
4. Conjunto de cuatro visualizaciones analíticas que cubren las perspectivas temporal, geográfica, de producto y de relación precio-demanda.

7.2 Conclusiones de Negocio

El análisis de los datos de ventas de Oriental Mercantil S.R.L. a través del pipeline KDD generó los siguientes hallazgos de negocio:

- La distribución geográfica de las ventas no es uniforme, existiendo zonas con alto potencial de crecimiento que podrían beneficiarse de mayor inversión comercial.
- El portafolio de productos presenta una concentración de ingresos en un subconjunto reducido del catálogo total, lo que sugiere oportunidades de optimización del mix de productos.
- Los patrones temporales identificados permiten anticipar periodos de alta y baja demanda, facilitando la planificación de inventario y recursos humanos.
- La relación precio-cantidad exhibe patrones diferenciados según el segmento de producto, lo que sugiere estrategias de pricing diferenciadas por categoría.

7.3 Recomendaciones Estratégicas

7.3.1 Recomendaciones de Corto Plazo

1. Implementar un dashboard ejecutivo en Power BI conectado directamente a las tablas Gold de Databricks para monitoreo continuo de KPIs comerciales.

2. Establecer alertas automáticas basadas en umbrales de TotalVenta mensual por zona para detectar desviaciones respecto al histórico.
3. Priorizar el reabastecimiento de los 15 productos del Top de ingresos para minimizar pérdidas de ventas por quiebre de stock.

7.3.2 Recomendaciones de Mediano Plazo

1. Extender el modelo estrella incorporando una DimCliente que permita análisis de comportamiento de compra y segmentación de cartera.
2. Implementar un proceso de carga incremental (CDC) para reemplazar las cargas completas actuales (modo 'overwrite'), reduciendo tiempos de procesamiento y costos computacionales.
3. Explorar la incorporación de datos externos (índices de precio de tecnología, tasas de cambio Bs./USD) para enriquecer el contexto analítico.

7.3.3 Recomendaciones de Largo Plazo

1. Considerar la migración a Databricks Standard o Premium para habilitar procesamiento en tiempo real (Structured Streaming) sobre el flujo transaccional del sistema de ventas.
2. Desarrollar modelos predictivos de demanda sobre las tablas Gold para optimizar la cadena de suministro de productos tecnológicos.
3. Certificar el proceso bajo un marco de gobernanza de datos (por ejemplo, DAMA-DMBOK) que formalice las reglas de calidad aplicadas y garantice su sostenibilidad organizacional.

Referencias

Databricks. (2023). The medallion lakehouse architecture. Databricks Documentation. <https://docs.databricks.com/lakehouse/medallion.html>

Fayyad, U., Piatetsky-Shapiro, G., & Smyth, P. (1996). From data mining to knowledge discovery in databases. *AI Magazine*, 17(3), 37–54. <https://doi.org/10.1609/aimag.v17i3.1230>

Han, J., Kamber, M., & Pei, J. (2022). *Data mining: Concepts and techniques* (4th ed.). Morgan Kaufmann.

Inmon, W. H. (2005). *Building the data warehouse* (4th ed.). Wiley.

Kimball, R., & Ross, M. (2013). *The data warehouse toolkit: The definitive guide to dimensional modeling* (3rd ed.). Wiley.

Kleppmann, M. (2017). *Designing data-intensive applications: The big ideas behind reliable, scalable, and maintainable systems*. O'Reilly Media.

Lakshmanan, V., Robinson, S., & Munn, M. (2020). *Machine learning design patterns*. O'Reilly Media.

Provost, F., & Fawcett, T. (2013). *Data science for business: What you need to know about data mining and data-analytic thinking*. O'Reilly Media.

Anexo: Descripción del Notebook de Databricks

El notebook de Databricks implementado para este proyecto contiene 12 celdas de código PySpark organizadas en tres secciones que corresponden a las capas Bronze, Silver y Gold del modelo medallón. A continuación se describe el propósito de cada celda:

Celda	Capa	Propósito Principal
Celda 1	Global	Configuración de variables de entorno y rutas de tablas del Unity Catalog
Celda 2	Bronze	Ingesta desde Unity Catalog con inyección de metadatos de auditoría
Celda 3	Bronze	Reporte de control: conteo de filas, columnas, muestra y esquema
Celda 4	Silver	Aplicación de Reglas 0-4 de limpieza y transformación secuencial
Celda 5	Silver	Proyección final con tipado explícito y persistencia en Delta Silver
Celda 6	Silver	Auditoría metrológica: verificación de nulos y rangos de valores
Celda 7	Gold	Construcción de DimTiempo y DimZona con claves sustitutas
Celda 8	Gold	Construcción de DimProducto con clave sustituta ProductSK
Celda 9	Gold	Ensamblaje de Fact_Ventas y validación de integridad referencial
Celda 10	Gold	Visualización: Evolución mensual de ingresos (gráfico de barras)
Celda 11	Gold	Visualización: Top zonas y top productos (gráfico doble)
Celda 12	Gold	Visualización: Top 15 productos y dispersión precio vs. cantidad

Nota. El notebook completo fue exportado en formato HTML como evidencia de ejecución y se adjunta como archivo separado al presente informe.

Todas las celdas fueron ejecutadas en Databricks Community Edition con un clúster de nodo único configurado con Apache Spark 3.x y Delta Lake habilitado. Los tiempos de ejecución son compatibles con los límites de la edición comunitaria gratuita, lo que demuestra la viabilidad de implementar arquitecturas medallón de producción sin costos de infraestructura durante las fases de prototipado y validación académica.